

Laporan Praktikum Kontrol Cerdas Week 5

Nama : Bintang Ramadhan
NIM : 224308079
Kelas : TKA 7D
Akun Github (Tautan) : <https://github.com/bintangramadhan10>
Students Lab Assistant : -

1. Judul Laporan

Deep Reinforcement Learning untuk Kontrol Kompleks.

2. Tujuan Percobaan

- Memahami konsep Deep Reinforcement Learning (DRL) dalam kontrol sistem kompleks.
- Mengimplementasikan Deep Q-Network (DQN) untuk kontrol otomatis.
- Menganalisis performa DRL dibandingkan dengan metode kontrol konvensional.

3. Landasan Teori

Reinforcement Learning (RL) adalah salah satu paradigma pembelajaran mesin di mana agen belajar melalui interaksi dengan lingkungan untuk memaksimalkan reward kumulatif jangka panjang. Berbeda dengan supervised learning yang membutuhkan dataset berlabel, dalam RL agen mempelajari strategi (policy) melalui trial-and-error berdasarkan balikan (reward) dari setiap aksi yang diambil. Tujuan utama RL adalah menemukan kebijakan optimal yang dapat menghasilkan performa terbaik dalam suatu tugas pengendalian (Barto, A. G., 2018).

Salah satu algoritma populer dalam RL adalah Deep Q-Network (DQN), yang menggabungkan Q-Learning dengan jaringan saraf tiruan. Q-Learning menggunakan fungsi nilai aksi (action-value function) untuk mengestimasi ekspektasi reward kumulatif suatu pasangan state-action. Namun, pendekatan Q-table tradisional tidak efisien untuk ruang keadaan

yang besar atau kontinu. DQN mengatasi keterbatasan ini dengan menggunakan deep neural network sebagai approximator fungsi Q, sehingga mampu mempelajari hubungan kompleks antar state dan action (Mnih, V., 2015).

Dalam praktiknya, DQN dilengkapi dengan dua teknik utama: (1) Experience Replay, yaitu penyimpanan pengalaman agen dalam buffer untuk kemudian di-sampling secara acak saat pelatihan sehingga mengurangi korelasi antar data, dan (2) Target Network, yaitu salinan jaringan Q yang diperbarui secara berkala untuk mencegah osilasi nilai Q. Kedua teknik ini meningkatkan stabilitas pembelajaran DQN (Sewak, 2019).

Pada praktikum ini digunakan environment Pendulum-v1 sebagai representasi pengendalian lengan robot sederhana. Pendulum merupakan kasus kontrol non-linear yang menantang karena agen harus menemukan strategi untuk menyeimbangkan lengan pada posisi tegak dengan aksi berupa gaya torsi kontinu. Untuk dapat diterapkan pada DQN, aksi kontinu didiskretisasi menjadi beberapa nilai tetap (misalnya -2.0 , 0.0 , dan 2.0), sehingga dapat diproses oleh jaringan Q (Brockman et al., 2016).

Jika dibandingkan dengan metode kontrol klasik seperti PID dan Fuzzy Logic, terdapat perbedaan mendasar dalam cara memperoleh strategi pengendalian. PID mengandalkan parameter K_p , K_i , dan K_d yang ditentukan melalui tuning manual, sementara Fuzzy Logic menggunakan aturan linguistik berbasis pakar. Kedua metode tersebut relatif cepat dan stabil pada kasus sederhana, tetapi membutuhkan desain awal yang teliti. Sebaliknya, DQN mampu belajar secara otonom dari interaksi dengan environment tanpa memerlukan aturan eksplisit, sehingga lebih fleksibel terutama untuk masalah kontrol yang kompleks. Namun, kekurangannya adalah kebutuhan komputasi yang besar, waktu pelatihan yang lama, serta kemungkinan hasil yang belum optimal bila jumlah episode training terbatas atau perangkat keras kurang mendukung.

4. Diskusi

Pada percobaan Deep Q-Network (DQN) menggunakan PyTorch di environment CartPole-v1, dilakukan pengujian sebanyak 5 episode setelah training. Hasil yang diperoleh menunjukkan bahwa agen masih memiliki performa rendah, dengan skor 21.0, 23.0, 18.0, 16.0, dan 25.0, sehingga rata-ratanya sekitar 20,6. Nilai ini masih jauh dari skor maksimum 500, yang berarti agen belum mampu menemukan strategi kontrol yang efektif untuk menjaga tiang tetap seimbang dalam waktu lama. Kondisi ini dapat disebabkan oleh beberapa faktor, antara lain jumlah episode training yang masih terbatas, penggunaan parameter seperti gamma, epsilon, dan learning rate yang belum optimal, serta belum diterapkannya teknik tambahan seperti target network atau double DQN yang biasanya digunakan untuk meningkatkan stabilitas pembelajaran.

Performa yang diperoleh ini sangat berbeda dengan percobaan pada praktikum minggu sebelumnya, di mana agen dapat mencapai skor hampir maksimal. Hal tersebut menunjukkan bahwa reinforcement learning sangat sensitif terhadap konfigurasi parameter, jumlah episode training, serta strategi eksplorasi yang digunakan. Tantangan utama dalam reinforcement learning adalah menjaga keseimbangan antara eksplorasi dan eksploitasi. Berbeda dengan supervised learning yang mengandalkan dataset tetap, reinforcement learning menuntut agen belajar dari interaksi langsung dengan lingkungan, sehingga lebih rentan terhadap kegagalan strategi jika eksplorasi tidak cukup.

Berdasarkan hasil tersebut, dapat disimpulkan bahwa agen DQN pada percobaan ini belum mencapai performa yang optimal, namun eksperimen ini memberikan gambaran penting mengenai bagaimana parameter dan teknik yang digunakan memengaruhi kinerja agen. Untuk percobaan selanjutnya, disarankan memperpanjang jumlah training episode menjadi 1000 atau lebih, menyesuaikan parameter pembelajaran, serta menambahkan teknik stabilisasi seperti target network. Selain itu, eksplorasi strategi lain seperti Boltzmann exploration atau penggunaan




algoritma lanjutan seperti Double DQN juga dapat membantu meningkatkan performa. Dengan perbaikan tersebut, metode reinforcement learning diharapkan dapat memberikan hasil yang lebih baik, dan pada akhirnya berpotensi diterapkan pada berbagai sistem kendali nyata seperti robotika, autonomous driving, maupun kontrol proses industri.

5. Assignment

Pada praktikum ini dilakukan modifikasi kode Deep Q-Network (DQN) untuk kasus kontrol Pendulum-v1 sebagai representasi sederhana dari pengendalian lengan robot. Pendulum merupakan environment klasik dalam reinforcement learning yang membutuhkan strategi pengendalian non-linear agar lengan dapat tetap tegak seimbang. Model DQN dilatih dengan mendiskretkan aksi kontinu menjadi tiga pilihan $[-2.0, 0.0, 2.0]$, kemudian dievaluasi sebanyak 10 episode pengujian.

Hasil pengujian menunjukkan bahwa agen masih gagal mencapai performa optimal. Nilai reward yang diperoleh berada pada kisaran -1415.56 hingga -1579.46 , dengan rata-rata sekitar -1500 . Nilai ini menunjukkan bahwa agen belum mampu mengontrol pendulum secara efektif. Penyebab utama rendahnya performa adalah karena proses training hanya dilakukan selama 500 episode akibat keterbatasan perangkat, sehingga agen tidak memiliki cukup waktu untuk belajar strategi yang lebih baik. Selain itu, permasalahan eksplorasi dan konvergensi pada DQN juga berkontribusi terhadap hasil yang kurang stabil.

6. Data dan Output Hasil Pengamatan

No	Perbandingan	CartPole-v1	Pendulum-v1
1.	Jumlah Episode Training	Pada training cartpole karena cukup ringan saya buat menjadi 1000 episode. Namun hasilnya masih naik turun.	Pada training pendulum karena lebih berat dari cartpole, saya buat menjadi 500 episode. Namun hasilnya masih naik turun.
2.	Hasil Training	Reward mencapai nilai maksimum 499 dan stabil pada beberapa episode terakhir. 	Reward rata-rata sekitar -1500, menunjukkan agen gagal menyeimbangkan lengan. 
3.	Hasil Testing	Agen mampu menjaga tiang tetap seimbang dengan reward tinggi (di atas 400 pada episode tertentu). 	Agen memperoleh reward yang kurang baik, antara -1415 hingga -1579, menandakan kegagalan program belum cukup stabil. 

4.	Kompleksitas Environment	CartPole-v1 relatif sederhana karena hanya mengatur pergerakan kereta agar tiang tetap seimbang. Dinamika lingkungannya lebih mudah dipelajari agen, sehingga reward positif lebih cepat diperoleh.	Pendulum-v1 jauh lebih kompleks karena melibatkan sistem non-linear. Agen harus belajar mengendalikan momentum dan gaya torsi agar lengan tetap tegak, yang membuat proses pembelajaran lebih sulit.
5.	Waktu Training	Training berlangsung lebih cepat karena lingkungan sederhana dan sinyal reward jelas. Performa agen meningkat stabil bahkan sebelum mencapai 1000 episode.	Training berlangsung lebih lama karena sinyal reward bersifat sparse (jarang) dan lingkungan lebih menantang. Dengan jumlah episode terbatas (500), agen belum cukup waktu untuk menemukan strategi optimal.

7. Kesimpulan

Berdasarkan praktikum dan analisis yang telah dilakukan dapat disimpulkan bahwa:

- Implementasi algoritma Deep Q-Network (DQN) pada environment CartPole-v1 berhasil dengan baik. Agen mampu mencapai reward maksimum 499 secara konsisten pada fase testing.
- Pada environment Pendulum-v1, performa agen masih lemah dengan reward antara -1415 hingga -1579 . Hal ini menunjukkan bahwa strategi kontrol yang dipelajari belum optimal.
- Perbedaan performa ini disebabkan oleh tingkat kompleksitas environment. CartPole relatif sederhana dengan dinamika linier,

sedangkan Pendulum merupakan sistem non-linear yang lebih sulit dikendalikan.

- Jumlah episode training yang terbatas (500 episode pada Pendulum) akibat keterbatasan perangkat juga menjadi faktor rendahnya kinerja agen. Agen tidak memiliki cukup waktu untuk mempelajari strategi yang lebih baik.
- Secara umum, DQN terbukti mampu bekerja efektif pada kasus sederhana, namun memerlukan penyesuaian parameter dan jumlah training yang lebih besar pada kasus kompleks seperti Pendulum.

8. Saran

Untuk penelitian dan praktikum selanjutnya, sebaiknya jumlah training pada environment kompleks seperti Pendulum diperpanjang hingga lebih dari 1000 episode agar agen memiliki waktu yang cukup untuk belajar strategi optimal. Selain itu, perlu dilakukan eksplorasi terhadap variasi parameter seperti gamma, epsilon decay, dan learning rate agar pembelajaran lebih stabil. Jika memungkinkan, penggunaan teknik lanjutan seperti Target Network atau Double DQN juga bisa dicoba untuk meningkatkan stabilitas dan akurasi pembelajaran. Tidak kalah penting, spesifikasi perangkat yang lebih tinggi akan sangat membantu mempercepat proses training yang membutuhkan perhitungan intensif.

9. Daftar Pustaka

- Barto, A. G., S., R. S. (2018). *Reinforcement Learning: An Introduction* (2nd ed.). MIT Press.
<http://incompleteideas.net/book/RLbook2020.pdf>
- Brockman, G., Cheung, V., Pettersson, L., Schneider, J., Schulman, J., Tang, J., & Zaremba, W. (2016). *OpenAI Gym* (No. arXiv:1606.01540). arXiv.
<https://doi.org/10.48550/arXiv.1606.01540>
- Mnih, V., Kavukcuoglu, K. (2015). *Human-level control through deep reinforcement learning*. *Nature*, 518(7540), 529–533.
<https://doi.org/DOI:%2520https://doi.org/10.1038/nature14236>
- Sewak, M. (2019). Deep Q Network (DQN), Double DQN, and Dueling DQN: A Step Towards General Artificial Intelligence. In M.

Sewak, *Deep Reinforcement Learning* (pp. 95–108). Springer Singapore. https://doi.org/10.1007/978-981-13-8285-7_8